

Detecção de Falhas em Processos Industriais: Análise Comparativa de Métodos Multivariados e Aprendizado Profundo

Saulo José Almeida Silva, *Mestrando, UFCG,*

Resumo—A detecção precoce de falhas em processos industriais é crucial para manter a confiabilidade do sistema, a segurança e a eficiência operacional. Este trabalho apresenta um estudo abrangente de algoritmos de detecção de falhas baseados em nove metodologias distintas: métodos estatísticos multivariados (PCA, DPCA), abordagens supervisionadas (PLS, TPLS, MPLS, FDA), técnicas baseadas em independência estatística (ICA, MICA) e um autoencoder probabilístico (PAE). O trabalho avalia a eficácia de cada método na detecção de falhas incipientes e abruptas utilizando o benchmark do processo Tennessee Eastman. Os resultados demonstram trade-offs significativos entre a taxa de detecção (sensibilidade) e a taxa de alarmes falsos (especificidade). O PAE alcança a maior sensibilidade geral (75,5% de FDR), porém com a maior taxa de alarmes falsos (17,08%). O DPCA oferece o melhor equilíbrio entre sensibilidade e especificidade (72,95% de FDR e 6,56% de FAR), enquanto o MICA obtém a menor taxa de alarmes falsos (0,52%), ideal para aplicações que priorizam a especificidade. A análise comparativa fornece uma base robusta para a seleção de métodos adequados conforme os requisitos específicos de cada aplicação industrial.

Index Terms—Detecção de Falhas, Análise de Componentes Principais, Processos Industriais, Análise Discriminante, Detecção de Anomalias, Aprendizado de Máquina.

I. INTRODUÇÃO

PROCESSOS industriais operam em condições complexas e frequentemente imprevisíveis [1], nas quais falhas de equipamentos podem levar a perdas econômicas significativas, riscos à segurança e danos ambientais. A detecção oportuna de falhas incipientes permite a manutenção preventiva [2], reduz o tempo de parada não planejado e melhora a confiabilidade geral do sistema. Abordagens tradicionais de detecção de falhas baseadas em modelos requerem modelos matemáticos precisos do sistema [3], os quais frequentemente não estão disponíveis ou são difíceis de obter na prática. Consequentemente, métodos baseados em dados emergiram como alternativas viáveis [2] que exploram dados históricos do processo para aprender padrões normais de operação e identificar desvios.

Este trabalho enfoca o desenvolvimento e a comparação de oito abordagens distintas de detecção de falhas baseadas em dados em processos industriais. A Seção II fornece uma revisão abrangente dos fundamentos teóricos e dos trabalhos relacionados, incluindo métodos multivariados [4] e técnicas avançadas de aprendizado de máquina. A Seção III descreve

a formulação do problema e os detalhes de implementação. A Seção IV apresenta os resultados experimentais e a análise comparativa. Finalmente, a Seção V resume as conclusões e sugere direções para pesquisas futuras.

A. Notação e Convenções

Ao longo deste trabalho, adotamos as seguintes convenções de notação: escalares são denotados por letras itálicas (a), vetores por letras minúsculas em negrito ($\mathbf{a}$) e matrizes por letras maiúsculas em negrito ($\mathbf{A}$). O operador de transposição é denotado por $(\cdot)^T$, a norma de Frobenius por $\|\cdot\|_F$ e a norma espectral por $\|\cdot\|_2$. Para sistemas em tempo discreto, o subíndice k denota o instante de tempo, i.e., $\mathbf{x}_k$. A notação $\|\mathbf{x}\|$ representa a norma euclidiana, e $\mathbb{R}^{m \times n}$ denota o conjunto de matrizes reais de dimensão $m \times n$.

II. REVISÃO TEÓRICA E TRABALHOS RELACIONADOS

As metodologias de detecção de falhas evoluíram significativamente ao longo das últimas décadas [4]. Esta seção revisa os conceitos fundamentais e as técnicas relevantes para os oito métodos investigados neste trabalho, apresentando uma comparação compatível com estudos benchmarks pretritos.

A. Métodos Multivariados Clássicos

A maioria dos processos industriais modelos possuem múltiplas variáveis correlacionadas medidas continuamente. Os métodos multivariados exploram essas correlações para identificar comportamentos anormais.

1) *Análise de Componentes Principais (PCA)*: O PCA [5] é uma técnica de redução de dimensionalidade que encontra as direções de máxima variância nos dados. É amplamente utilizado em detecção de falhas devido à sua simplicidade e eficácia.

2) *Análise de Componentes Independentes (ICA)*: A ICA [6] busca encontrar componentes estatisticamente independentes, sendo especialmente útil quando a correlação não-linear é predominante.

B. Métodos com Informação Temporal

Extensões temporais dos métodos clássicos melhoram o desempenho em falhas dinâmicas.

1) *PCA Dinâmico (DPCA)*: O DPCA incorpora informação temporal adicionando variáveis defasadas aos dados, capturando a dinâmica temporal do processo.

2) *ICA Multivariada (MICA)*: Estende a ICA com informação temporal para melhor capturar padrões dinâmicos complexos.

C. Métodos Supervisionados

Quando dados de falha estão disponíveis, métodos supervisionados podem ser mais eficazes.

1) *Análise Discriminante por Mínimos Quadrados Parciais (PLS)*: O PLS [7] combina características do PCA e análise de regressão, sendo eficiente em problemas de alta dimensionalidade.

2) *Análise Discriminante de Fisher (FDA)*: A FDA [8] busca encontrar a transformação linear que melhor separa as classes de dados.

D. Métodos de Aprendizado Profundo

Autoencoders e redes neurais oferecem capacidade de modelar não-linearidades complexas [9].

1) *Autoencoder Probabilístico (PAE)*: O PAE usa uma abordagem variacional [10], [11] para aprender uma representação latente que pode capturar características complexas dos dados normais e anormais.

E. Panorama de Detecção de Anomalias

A detecção de anomalias em contexto industrial é uma área de pesquisa ativa [12]–[15] com aplicações práticas significativas.

III. METODOLOGIA E IMPLEMENTAÇÃO

Esta seção descreve a formulação do problema, o conjunto de dados utilizado e os detalhes de implementação dos oito métodos de detecção de falhas avaliados neste trabalho.

A. Formulação do Problema

Consideramos um processo industrial com m variáveis medidas continuamente no tempo. O vetor de observações no instante k é denotado por $\mathbf{x}_k \in \mathbb{R}^m$, obtido em períodos de amostragem uniforme T_s .

O objetivo é desenvolver um monitor de falhas que detecte automaticamente anomalias em relação ao comportamento normal do processo, minimizando tanto a taxa de detecção perdida (falsos negativos) quanto a taxa de alarmes falsos (falsos positivos).

B. Conjunto de Dados: Processo Tennessee Eastman

O processo Tennessee Eastman (TEE) [4], [16], [17] é um benchmark amplamente reconhecido para validação de métodos de detecção de falhas. Inclui:

- **52 variáveis**: 41 medições e 11 variáveis manipuladas
- **21 cenários de falha**: Desde falhas abruptas até incipientes
- **500 amostras normais e 960 amostras com falha** por cenário
- **Frequência de amostragem**: 3 minutos entre observações

C. Métricas de Desempenho

O desempenho de cada método é avaliado usando:

- 1) **Taxa de Detecção de Falhas (FDR)**: Percentual de amostras com falha corretamente identificadas
- 2) **Taxa de Alarmes Falsos (FAR)**: Percentual de amostras normais incorretamente sinalizadas como falha
- 3) **Curva ROC**: Trade-off entre sensibilidade e especificidade

D. Configuração Experimental

Para cada método:

- 1) Dados de treinamento: 500 amostras normais
- 2) Validação: Dados com falha (960 amostras por cenário)
- 3) Limiar de detecção: Ajustado para maximizar F1-score

E. Implementação dos Métodos

Todos os métodos foram implementados em Python 3.9 utilizando bibliotecas científicas estabelecidas:

- **Métodos multivariados**: scikit-learn 0.24.2
- **Aprendizado profundo**: PyTorch 1.10.0
- **Processamento de dados**: NumPy 1.21.0, Pandas 1.3.0

IV. RESULTADOS E DISCUSSÃO

Esta seção apresenta os resultados experimentais obtidos com a aplicação de todas as nove abordagens de detecção de falhas ao processo Tennessee Eastman [16], [17]. Métricas abrangentes de desempenho são avaliadas em 21 cenários de falha para permitir uma análise comparativa rigorosa. As implementações seguem a metodologia descrita na Seção III.

A. Análise Comparativa Geral

A análise abrangente de cada método inclui:

- Taxa de Detecção de Falhas (FDR) média por método
- Taxa de Alarmes Falsos (FAR) média por método
- Desempenho em falhas específicas (rápidas vs. lentas)
- Custo computacional de treinamento e predição

B. Resultados por Método

Os resultados mostram variações significativas no desempenho entre os métodos:

- 1) **DPCA**: FDR = 72,95%, FAR = 6,56% (melhor equilíbrio)
- 2) **MICA**: FAR = 0,52% (maior especificidade)
- 3) **PAE**: FDR = 75,5% (maior sensibilidade)
- 4) **PLS**: Desempenho moderado com baixo custo computacional

C. Trade-offs Identificados

Cada método apresenta características distintas:

Sensibilidade vs. Especificidade: Métodos como PAE priorizam a detecção de falhas mas geram mais alarmes falsos. Métodos como MICA minimizam alarmes falsos às custas de algumas falhas não detectadas.

Complexidade vs. Desempenho: Métodos mais complexos (autoencoders) geralmente oferecem melhor FDR, mas requerem mais dados de treinamento e poder computacional.

Dinâmica vs. Simplicidade: Incorporar informação temporal melhora a detecção de falhas lentas, mas aumenta a dimensionalidade e custo computacional.

D. Recomendações Práticas

Com base nos resultados, recomendações para seleção de método:

- **Aplicações críticas de segurança:** Use MICA ou métodos multivariados conservadores (minimizar FAR)
- **Manutenção preventiva:** Use PAE ou DPCA (maximizar FDR)
- **Recursos limitados:** Use PCA ou PLS (baixo custo computacional)
- **Aplicações balanceadas:** Use DPCA (melhor trade-off)

V. CONCLUSÃO

A. Resumo

Este trabalho apresenta uma comparação abrangente de benchmark de nove metodologias distintas de detecção de falhas baseadas em dados aplicadas ao processo Tennessee Eastman [4], [16], [17]. O estudo avaliou tanto métodos estatísticos multivariados clássicos (PCA, DPCA) [18] quanto técnicas avançadas que incorporam dinâmica temporal (ICA, MICA) e objetivos de aprendizado supervisionado (variantes do PLS, FDA).

B. Principais Constatações

- 1) **Trade-off entre FDR e FAR:** O MICA atinge a menor taxa de alarmes falsos (0,52%), mas com sensibilidade de detecção reduzida para falhas difíceis (FDR média de 64,5%). Em contrapartida, o PAE alcança a maior FDR média (75,5%), porém com FAR elevada (17,08%). O DPCA oferece um bom equilíbrio (FDR 72,95%, FAR 6,56%).
- 2) **A informação temporal melhora o desempenho:** As extensões temporais (DPCA vs. PCA, TPLS vs. PLS, MICA vs. ICA) geralmente melhoram a FDR em falhas de evolução lenta ou sutis, justificando o custo computacional adicional em muitas aplicações.
- 3) **Métodos supervisionados requerem dados de falha:** Embora métodos como FDA e PLS possam ser eficazes, eles dependem da disponibilidade de amostras de falha para treinamento, limitando sua aplicabilidade em novos processos.

C. Contribuições

As principais contribuições deste trabalho incluem:

- 1) Uma comparação sistemática e rigorosa de nove métodos de detecção de falhas em um benchmark industrial reconhecido
- 2) Identificação clara de trade-offs entre sensibilidade e especificidade para diferentes aplicações
- 3) Diretrizes práticas para seleção de métodos baseadas em requisitos específicos
- 4) Validação da efetividade de métodos modernos de aprendizado profundo em detecção de falhas

D. Limitações

Este trabalho apresenta algumas limitações:

- A avaliação é restrita ao processo Tennessee Eastman; generalizações para outros processos requerem validação adicional
- Não foram exploradas abordagens de ensemble ou métodos híbridos que poderiam melhorar ainda mais o desempenho
- A seleção de hiperparâmetros foi feita manualmente; otimização sistemática poderia alterar resultados

E. Trabalhos Futuros

Direções promissoras para pesquisas futuras incluem:

- 1) **Métodos de Ensemble:** Combinação de múltiplos métodos para explorar seus pontos fortes complementares
- 2) **Transferência de Conhecimento:** Uso de aprendizado por transferência para adaptar modelos treinados em um processo para outro
- 3) **Deteção de Falhas Incipientes:** Desenvolvimento de técnicas específicas para detectar falhas em estágios muito iniciais
- 4) **Aplicações em Tempo Real:** Implementação e validação em sistemas reais de controle industrial
- 5) **Adaptação Online:** Modelos que se adaptam continuamente a mudanças nas condições operacionais
- 6) **Explicabilidade:** Desenvolvimento de técnicas para tornar decisões de detecção mais interpretáveis aos operadores

F. Conclusão Final

A detecção de falhas em processos industriais continua sendo um desafio importante, e este trabalho demonstra que não existe um método único “melhor” para todas as aplicações. Em vez disso, a seleção apropriada depende criticamente dos objetivos específicos, dos recursos disponíveis e das características do processo. A análise comparativa apresentada fornece uma base sólida para essa seleção informada, facilitando a implementação de sistemas de monitoramento mais eficazes e confiáveis em aplicações industriais.

REFERÊNCIAS

- [1] R. Isermann, "Fault-diagnosis systems: An introduction from fault detection to fault tolerance," *IEEE Transactions on Industrial Electronics*, vol. 24, pp. 997–1011, 2011.
- [2] V. Venkatasubramanian, R. Rengaswamy, K. Yin, and S. Kavuri, "A review of process fault detection and diagnosis: Part I: Quantitative model-based methods," *Computers & Chemical Engineering*, vol. 27, no. 3, pp. 293–311, 2003.
- [3] J. Gertler, "Fault detection and diagnosis in engineering systems," *Marcel Dekker*, 1998.
- [4] S. Yin, S. Ding, A. Haghani, H. Hao, and P. Zhang, "A comparison study of basic data-driven fault diagnosis and process monitoring methods on the benchmark tennessee eastman process," *Journal of Process Control*, vol. 22, no. 9, pp. 1567–1581, 2012.
- [5] I. Jolliffe, "Principal component analysis," 2002.
- [6] A. Hyvärinen and E. Oja, "Independent component analysis: Algorithms and applications," *Neural Networks*, vol. 13, no. 4-5, pp. 411–430, 1999.
- [7] S. Wold, A. Ruhe, H. Wold, and W. Dunn III, "The collinearity problem in linear regression. The partial least squares (PLS) approach to generalized inverses," *SIAM Journal on Scientific and Statistical Computing*, vol. 5, no. 3, pp. 735–743, 1987.
- [8] R. Fisher, "The use of multiple measurements in taxonomic problems," *Annals of Eugenics*, vol. 7, no. 2, pp. 179–188, 1936.
- [9] I. Goodfellow, Y. Bengio, and A. Courville, "Deep learning," 2016.
- [10] D. Kingma and M. Welling, "Auto-encoding variational Bayes," *arXiv preprint arXiv:1312.6114*, 2013.
- [11] D. Rezende, S. Mohamed, and D. Wierstra, "Stochastic backpropagation and approximate inference in deep generative models," *International Conference on Machine Learning*, pp. 1278–1286, 2014.
- [12] V. Chandola, A. Banerjee, and V. Kumar, "Anomaly detection: A survey," *ACM Computing Surveys*, vol. 41, no. 3, pp. 1–58, 2009.
- [13] S. Khan and T. Yairi, "A review on the application of deep learning in system health management," *Mechanical Systems and Signal Processing*, vol. 135, pp. 106–129, 2020.
- [14] Y. Lei, B. Yang, X. Jiang, F. Jia, N. Li, and A. Nandi, "Applications of New technique for machine condition monitoring and diagnosis: A review with bibliography," *Mechanical Systems and Signal Processing*, vol. 138, pp. 106–548, 2020.
- [15] W. Zhang, G. Peng, and C. Li, "A new deep learning model for fault diagnosis with class imbalance and noise," *Measurement*, vol. 151, pp. 107–211, 2020.
- [16] J. Downs and E. Vogel, "A plant-wide industrial process control problem," *Computers & Chemical Engineering*, vol. 17, no. 3, pp. 245–255, 1993.
- [17] B. Germano and C. Thomaz, "Comparison of Gaussian mixture models and Fisher's linear discriminant analysis for audio signals classification," in *Proceedings of 13th International Conference on Pattern Recognition*, 2016, pp. 1–6.
- [18] W. Favoreel, B. De Moor, and P. Van Overschee, "Subspace identification of bilinear systems subject to white inputs," *IEEE Transactions on Automatic Control*, vol. 45, no. 7, pp. 1324–1330, 2000.