

Filtragem de Kalman em Sistemas de Visão Computacional: Rastreamento Bidimensional de Alvos Sob Oclusão

Saulo José Almeida Silva, *Mestrando, UFCG*,

Resumo—Este trabalho apresenta o desenvolvimento e a validação experimental de um sistema de rastreamento bidimensional baseado na fusão de visão computacional e Filtragem de Kalman. O sistema utiliza um algoritmo de segmentação por cor para detectar as coordenadas X e Y de um objeto alvo laranja sobre um fundo preto. Para mitigar os efeitos de ruídos de medição e, principalmente, lidar com situações de oclusão temporária do alvo, o Filtro de Kalman foi implementado para estimar e prever a trajetória contínua do objeto. Os resultados demonstram a robustez da abordagem, que mantém a precisão da localização robótica mesmo durante a perda completa do sinal visual, validando o método para aplicações em ambientes práticos e dinâmicos.

Index Terms—Filtro de Kalman, Visão Computacional, Rastreamento de Objetos, Oclusão, Robótica Móvel.

I. INTRODUÇÃO

ALGO

A. Notação e Convenções

Ao longo deste trabalho, adota-se um rigor matemático onde escalares são indicados por letras minúsculas em itálico (*a*), vetores por letras minúsculas em negrito (**a** ou **μ**) e matrizes por letras maiúsculas em negrito (**A** ou **Σ**).

No domínio do tempo discreto, o subscrito k denota o instante amostral atual (e.g., $\mathbf{x}_k$). Para os estimadores de estado, a notação subscrita $k|k-1$ ou o uso do símbolo superior em barra (como em $\bar{\mathbf{x}}_k$ ou $\bar{\mu}_k$) representam a estimativa *a priori* (etapa de predição), calculada com base no histórico até o instante $k-1$. Por sua vez, a notação $k|k$, ou o uso do índice k sem a barra ($\mathbf{x}_k$ ou μ_k), indica a estimativa *a posteriori* (estado corrigido), obtida após a incorporação da medição do instante atual.

II. REVISÃO TEÓRICA E TRABALHOS RELACIONADOS

As metodologias de localização e rastreamento em robótica evoluíram significativamente nas últimas décadas, impulsionadas pelo avanço da visão computacional [1]. Esta seção revisa os conceitos de sistemas estocásticos e suas discretizações, a formulação matemática da robótica probabilística e detalha o Filtro de Kalman (linear e estendido), estabelecendo a base teórica para o desenvolvimento deste trabalho.

S. J. A. Silva é mestrando no Programa de Pós-Graduação em Engenharia Elétrica (PPgEE) da Universidade Federal de Campina Grande (UFCG), Campina Grande, PB, Brasil. E-mail: saulo.jose.silva@ee.ufcg.edu.br.

A. Sistemas Dinâmicos Estocásticos

Sistemas robóticos operam em ambientes físicos e são modelados no espaço de estados. Contudo, devido a perturbações ambientais e limitações mecânicas, tornam-se estocásticos. A evolução do estado de um sistema em tempo discreto é regida por equações de transição e de medição, representadas abstratamente pelas leis de probabilidade dadas nas Equações (1) e (2):

$$\mathbf{x}_k \sim P(\mathbf{x}_k | \mathbf{x}_{k-1}, \mathbf{u}_k) \quad (1)$$

$$\mathbf{z}_k \sim P(\mathbf{z}_k | \mathbf{x}_k) \quad (2)$$

onde k é o índice do passo temporal discreto, $\mathbf{x}_k$ é o vetor de estado, $\mathbf{u}_k$ o comando de controle aplicado, e $\mathbf{z}_k$ a medição observada (como as coordenadas cartesianas advindas da visão).

B. Incertezas na Medição e no Modelo

A natureza estocástica descrita na Seção II-A manifesta-se através de dois ruídos principais [2]:

- 1) **Ruído de Processo:** Modela forças externas não mapeadas e imperfeições físicas que afetam a dinâmica do robô.
- 2) **Ruído de Medição:** Engloba as imprecisões inerentes aos sensores. Em sistemas de visão computacional, incluem-se variações de iluminação, ruído de discretização de pixels e desfoque de movimento [1].

O mapeamento rigoroso dessas incertezas é crucial para garantir a estabilidade dos estimadores em trajetórias complexas [3].

C. Discretização do Sistema e das Covariâncias

Os modelos cinemáticos são originalmente contínuos no tempo (t). Contudo, processadores embarcados operam em intervalos discretos de amostragem Δt . Assumindo um controle constante $\mathbf{u}_k$ aplicado no intervalo de amostragem, transforma-se o sistema contínuo linear $\dot{\mathbf{x}}(t) = \mathbf{A}_c \mathbf{x}(t) + \mathbf{B}_c \mathbf{u}(t)$ na sua contraparte discreta, apresentada na Equação (3):

$$\mathbf{x}_k = \mathbf{A}_k \mathbf{x}_{k-1} + \mathbf{B}_k \mathbf{u}_k \quad (3)$$

As matrizes de transição ($\mathbf{A}_k$) e de entrada ($\mathbf{B}_k$) presentes na Equação (3) são obtidas analiticamente por meio da Equação (4):

$$\mathbf{A}_k = e^{\mathbf{A}_c \Delta t} \quad \text{e} \quad \mathbf{B}_k = \int_0^{\Delta t} e^{\mathbf{A}_c \tau} \mathbf{B}_c d\tau \quad (4)$$

Discretização dos Erros (Incertezas): A discretização também afeta as matrizes de covariância dos ruídos discutidos na Seção II-B. A matriz de covariância do ruído de processo contínuo, $\mathbf{Q}_c$, propaga-se no tempo interagindo com a dinâmica do sistema. A matriz discreta equivalente $\mathbf{Q}_k$ é dada pela integração na Equação (5):

$$\mathbf{Q}_k = \int_0^{\Delta t} e^{\mathbf{A}_c \tau} \mathbf{Q}_c e^{\mathbf{A}_c^T \tau} d\tau \quad (5)$$

Para taxas de amostragem suficientemente rápidas (Δt pequeno), esta integração é comumente aproximada de forma linear por $\mathbf{Q}_k \approx \mathbf{Q}_c \Delta t$, indicando que a incerteza do modelo cresce proporcionalmente ao tempo entre as amostras.

Extensão para Sistemas Não-Lineares: Se o sistema for regido por dinâmicas não-lineares da forma $\dot{\mathbf{x}}(t) = f(\mathbf{x}(t), \mathbf{u}(t))$, aproxima-se a discretização por métodos numéricos (como o Método de Euler): $\mathbf{x}_k \approx \mathbf{x}_{k-1} + f(\mathbf{x}_{k-1}, \mathbf{u}_{k-1})\Delta t$. Para estimadores probabilísticos, o modelo discreto deve ser linearizado via matrizes Jacobianas a cada passo k para permitir a propagação da incerteza.

D. Robótica Probabilística e Suposição de Markov

Devido às incertezas já estabelecidas, introduz-se o conceito de *belief* (crença) para representar a distribuição de probabilidade a posteriori sobre o estado, condicionada aos dados passados [4], conforme denotado pela Equação (6):

$$bel(\mathbf{x}_k) = P(\mathbf{x}_k | \mathbf{z}_{1:k}, \mathbf{u}_{1:k}) \quad (6)$$

Para tornar o cálculo recursivo do *belief* viável, adota-se a **Suposição de Markov**. Ela postula que o estado atual $\mathbf{x}_k$ consolida toda a informação histórica necessária. Logo, o futuro é independente do passado se o estado presente for conhecido, simplificando a probabilidade para a forma da Equação (7):

$$P(\mathbf{x}_k | \mathbf{x}_{1:k-1}, \mathbf{u}_{1:k}, \mathbf{z}_{1:k-1}) = P(\mathbf{x}_k | \mathbf{x}_{k-1}, \mathbf{u}_k) \quad (7)$$

Essa suposição permite a quebra da equação do *belief* em etapas iterativas de predição e correção, formando a base algorítmica dos filtros detalhados a seguir [5].

E. Filtro de Kalman

O Filtro de Kalman (FK) [6] é uma implementação analítica do Filtro de Bayes para sistemas de domínio contínuo ou discreto, assumindo linearidade e que os ruídos (Seção II-B) seguem distribuições Gaussianas.

1) **Filtro de Kalman Linear:** Utilizando o sistema discretizado da Seção II-C, a dinâmica e a medição são descritas nas Equações (8) e (9) com a adição dos vetores de ruído de processo (ϵ_k) e medição (δ_k):

$$\mathbf{x}_k = \mathbf{A}_k \mathbf{x}_{k-1} + \mathbf{B}_k \mathbf{u}_k + \epsilon_k \quad (8)$$

$$\mathbf{z}_k = \mathbf{H}_k \mathbf{x}_k + \delta_k \quad (9)$$

sendo $\epsilon_k \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}_k)$ e $\delta_k \sim \mathcal{N}(\mathbf{0}, \mathbf{R}_k)$. O algoritmo estima recursivamente a média μ_k e a covariância Σ_k do

belief, dividindo o processo nas etapas de predição e correção, conforme estruturado no Algoritmo 1 [4].

Algorithm 1 Filtro de Kalman Linear

Require: $\mu_{k-1}, \Sigma_{k-1}, \mathbf{u}_k, \mathbf{z}_k$

Predição (Propagação do Modelo):

- 1: $\bar{\mu}_k \leftarrow \mathbf{A}_k \mu_{k-1} + \mathbf{B}_k \mathbf{u}_k$
- 2: $\bar{\Sigma}_k \leftarrow \mathbf{A}_k \Sigma_{k-1} \mathbf{A}_k^T + \mathbf{Q}_k$

Correção (Atualização pela Medição):

- 3: $\mathbf{K}_k \leftarrow \bar{\Sigma}_k \mathbf{H}_k^T (\mathbf{H}_k \bar{\Sigma}_k \mathbf{H}_k^T + \mathbf{R}_k)^{-1}$
- 4: $\mu_k \leftarrow \bar{\mu}_k + \mathbf{K}_k (\mathbf{z}_k - \mathbf{H}_k \bar{\mu}_k)$
- 5: $\Sigma_k \leftarrow (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \bar{\Sigma}_k (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k)^T + \mathbf{K}_k \mathbf{R}_k \mathbf{K}_k^T$

Ensure: μ_k, Σ_k

Em cenários de oclusão visual severa, a etapa de correção (linhas 4 a 6) é omitida, e o filtro opera unicamente via predição, propagando a incerteza do sistema de forma contínua.

2) **Filtro de Kalman Estendido (EKF):** Se o sistema possuir dinâmica não-linear, aplica-se o EKF [4]. Substituem-se as matrizes lineares por funções generalizadas g e h , como definido nas Equações (10) e (11):

$$\mathbf{x}_k = g(\mathbf{u}_k, \mathbf{x}_{k-1}) + \epsilon_k \quad (10)$$

$$\mathbf{z}_k = h(\mathbf{x}_k) + \delta_k \quad (11)$$

A linearização necessária para calcular as matrizes de covariância é obtida por meio de matrizes Jacobianas $\mathbf{G}_k$ e $\mathbf{H}_k$, avaliadas na estimativa atual, de acordo com as Equações (12) e (13):

$$\mathbf{G}_k = \left. \frac{\partial g(\mathbf{u}_k, \mathbf{x}_{k-1})}{\partial \mathbf{x}_{k-1}} \right|_{\mathbf{x}_{k-1} = \mu_{k-1}} \quad (12)$$

$$\mathbf{H}_k = \left. \frac{\partial h(\mathbf{x}_k)}{\partial \mathbf{x}_k} \right|_{\mathbf{x}_k = \mu_k} \quad (13)$$

Estas substituem as matrizes lineares $\mathbf{A}_k$ e $\mathbf{H}_k$ (vistas nas Equações 8 e 9) nas etapas de atualização de covariância e cálculo do ganho de Kalman ($\mathbf{K}_k$), viabilizando o rastreamento em geometrias mais complexas, conforme detalhado no Algoritmo 2.

Algorithm 2 Filtro de Kalman Estendido (EKF)

Require: $\mu_{k-1}, \Sigma_{k-1}, \mathbf{u}_k, \mathbf{z}_k$

Predição (Propagação do Modelo):

- 1: $\bar{\mu}_k \leftarrow g(\mathbf{u}_k, \mu_{k-1})$
- 2: $\mathbf{G}_k \leftarrow \text{Jacobiano}(g, \mathbf{u}_k, \mu_{k-1})$
- 3: $\bar{\Sigma}_k \leftarrow \mathbf{G}_k \Sigma_{k-1} \mathbf{G}_k^T + \mathbf{Q}_k$

Correção (Atualização pela Medição):

- 4: $\mathbf{H}_k \leftarrow \text{Jacobiano}(h, \bar{\mu}_k)$
- 5: $\mathbf{K}_k \leftarrow \bar{\Sigma}_k \mathbf{H}_k^T (\mathbf{H}_k \bar{\Sigma}_k \mathbf{H}_k^T + \mathbf{R}_k)^{-1}$
- 6: $\mu_k \leftarrow \bar{\mu}_k + \mathbf{K}_k (\mathbf{z}_k - h(\bar{\mu}_k))$
- 7: $\Sigma_k \leftarrow (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \bar{\Sigma}_k (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k)^T + \mathbf{K}_k \mathbf{R}_k \mathbf{K}_k^T$

Ensure: μ_k, Σ_k

III. VISÃO GERAL DO PROBLEMA

As metodologias de detecção de falhas evoluíram significativamente ao longo das últimas décadas [?]. Esta seção revisa os conceitos fundamentais e as técnicas relevantes para os oito métodos investigados neste trabalho, apresentando uma comparação compatível com estudos benchmarks pretritos.

IV. METODOLOGIA E IMPLEMENTAÇÃO

Esta seção descreve a formulação do problema, o conjunto de dados utilizado e os detalhes de implementação dos oito métodos de detecção de falhas avaliados neste trabalho.

A. Formulação do Problema

B. Métodos de avaliação

V. RESULTADOS E DISCUSSÃO

Esta seção apresenta os resultados experimentais obtidos com a aplicação de todas as nove abordagens de detecção de falhas ao processo Tennessee Eastman [?], [?]. Métricas abrangentes de desempenho são avaliadas em 21 cenários de falha para permitir uma análise comparativa rigorosa. As implementações seguem a metodologia descrita na Seção IV.

A. Análise Comparativa Geral

B. Resultados por Método

C. Recomendações Práticas

C

VI. CONCLUSÃO

A. Resumo

Este trabalho apresenta uma comparação abrangente de benchmark de nove metodologias distintas de detecção de falhas baseadas em dados aplicadas ao processo Tennessee Eastman [?], [?], [?]. O estudo avaliou tanto métodos estatísticos multivariados clássicos (PCA, DPCA) [?] quanto técnicas avançadas que incorporam dinâmica temporal (ICA, MICA) e objetivos de aprendizado supervisionado (variantes do PLS, FDA).

B. Principais Constatações

C. Contribuições

D. Limitações

E. Trabalhos Futuros

F. Conclusão Final

A detecção de falhas em processos industriais continua sendo um desafio importante, e este trabalho demonstra que não existe um método único “melhor” para todas as aplicações. Em vez disso, a seleção apropriada depende criticamente dos objetivos específicos, dos recursos disponíveis e das características do processo. A análise comparativa apresentada fornece uma base sólida para essa seleção informada, facilitando a implementação de sistemas de monitoramento mais eficazes e confiáveis em aplicações industriais.

REFERÊNCIAS

- [1] S. Y. Chen, “Kalman filter for robot vision: A survey,” *IEEE Transactions on Industrial Electronics*, vol. 59, no. 11, pp. 4409–4419, 2012.
- [2] G. Reina, A. Vargas, K. Nagatani, and K. Yoshida, “Adaptive kalman filtering for gps-based mobile robot localization,” in *Proceedings of the 2007 IEEE International Workshop on Safety, Security and Rescue Robotics (SSRR)*. Rome, Italy: IEEE, September 2007.
- [3] P. Fałek and P. Kaniewski, “Computer application for testing kalman filter,” in *Conference Proceedings of SPIE*, vol. 11442. SPIE, 2020, p. 1144213.
- [4] S. Thrun, W. Burgard, and D. Fox, *Probabilistic Robotics*, ser. Intelligent Robotics and Autonomous Agents series. Cambridge, MA, USA: The MIT Press, 2005.
- [5] Á. Odry, R. Fullér, I. J. Rudas, and P. Odry, “Kalman filter for mobile-robot attitude estimation: Novel optimized and adaptive solutions,” *Mechanical Systems and Signal Processing*, vol. 110, pp. 569–589, 2018.
- [6] R. E. Kalman, “A new approach to linear filtering and prediction problems,” *Transactions of the ASME—Journal of Basic Engineering*, vol. 82, no. Series D, pp. 35–45, 1960.